

这是一个已分享的 ChatGPT 聊天副本。它不会被添加到记忆中。

[举报对话](#)

设定

对某个 query row，记原始 attention logit 为 a_i 。history 集合为 H ，四个可见 sink 为 P 。令

$$r_j = \text{softmax}_H(s)_j = \frac{e^{s_j}}{\sum_{k \in H} e^{s_k}}.$$

则 $B > 0$ 时：

$$z_j = a_j + s_j - \text{LSE}_H(s) + \log B = a_j + \log(Br_j), \quad j \in H,$$

而 sink 上：

$$z_p = a_p, \quad p \in P.$$

1. History 内部关系：Claude 这部分正确

任意两个 history keys j, k ：

$$z_j - z_k = (a_j - a_k) + (s_j - s_k).$$

其中 $-\text{LSE}(s) + \log B$ 完全抵消。因此：

$$\frac{\alpha_j}{\alpha_k} = e^{a_j - a_k + s_j - s_k},$$

与 B 无关。

所以 B 不改变当前参数下的：

- history 内部 ranking；
- history 内部 attention odds；
- router score 的 Top-K 顺序；
- $r = \text{softmax}(s)$ 的 entropy 或 participation ratio。

但这只适用于 history-history 的内部关系。

2. History-vs-sink 关系：Claude 错误

一个 history key j 与 sink p 的 logit 差为：

$$z_j - z_p = (a_j - a_p) + s_j - \text{LSE}(s) + \log B.$$

所以：

$$\frac{\alpha_j}{\alpha_p} = B e^{a_j - a_p} r_j$$

B 每增大一倍，history 相对 sink 的 attention odds 就增大一倍。

令

$$Z_H = \sum_{j \in H} r_j e^{a_j}, \quad Z_P = \sum_{p \in P} e^{a_p},$$

则整个 history group 的最终 attention mass 是：

$$M_H(B) = \frac{B Z_H}{B Z_H + Z_P}$$

sink group 的 mass 是：

$$M_P(B) = \frac{Z_P}{B Z_H + Z_P}.$$

因此在当前 sink-4 配置中，B 不只是影响梯度；它直接改变 forward attention 的 history-vs-sink 分配。

3. 无 sink/无任何 ungated token 时：B 完全抵消

如果所有可见 key 都属于 history，没有 sink 或其他 gate 固定为0的 token：

$$\alpha_j(B) = \frac{e^{a_j} B r_j}{\sum_k e^{a_k} B r_k} = \frac{e^{a_j} r_j}{\sum_k e^{a_k} r_k}.$$

所以：

$$\alpha_j(B) = \alpha_j(1)$$

此时 B：

- 不影响 forward；
- 不影响 loss；
- 不影响 router 的实际梯度；
- 只是所有 logits 上的公共平移。

换句话说，B 只有在存在 sink、pinned token、local ungated token 等“参考组”时才可辨识。

4. Raw gate $s = 0$ 的 dense no-op 条件

Raw gate 定义为：

$$g_j = s_j, \quad j \in H,$$

sink gate 为：

$$g_p = 0.$$

要恢复 dense attention，加入的 gate 必须对所有可见 key 相同。由于 sink gate 已固定为 0，这个公共常数只能是 0，因此：

$$g_j = 0 \quad \forall j \in H$$

即：

$$s_j = 0 \quad \forall j \in H.$$

所以在有 sink 时，raw gate 的 $s = 0$ 是精确 dense no-op。

注意，raw gate 若只是 flat：

$$s_j = c,$$

但 $c \neq 0$ ，则 history 相对 sinks 整体偏移 c ，并不是 dense no-op。

无 sink 时则不同：任意 flat $s_j = c$ 都只是公共平移，因此都是 no-op。

5. Normalized flat gate 的 dense no-op 条件

设 history scores 完全 flat：

$$s_j = c, \quad n_H = |H|.$$

则：

$$\text{LSE}_H(s) = c + \log n_H.$$

所以每个 history gate 为：

$$g_j = c - (c + \log n_H) + \log B = \log \frac{B}{n_H}.$$

因为 sink gate 为 0，要恢复 dense attention，必须：

$$\log \frac{B}{n_H} = 0,$$

也就是：

$$\boxed{B = n_H.}$$

这也是充分且必要条件。更完整地写：

$$g_j = 0 \forall j \iff Br_j = 1 \forall j.$$

对所有 history keys求和：

$$\sum_j Br_j = B = n_H,$$

同时必须：

$$r_j = \frac{1}{n_H},$$

即 scores必须flat。

因此在有 sink 时：

$$\boxed{\text{normalized dense no-op} \iff s \text{ flat 且 } B = n_H.}$$

对于 fixed scalar B，由于 causal full-prefill 每一行的 $n_H(q)$ 不同，flat normalized gate只能在恰好满足：

$$n_H(q) = B$$

的那些行上成为精确 no-op。

如果未来使用逐行：

$$B_q = n_H(q),$$

那么 flat normalized gate会在每一行都成为精确 dense no-op。

无 sink 时，flat normalized gate无论 B 取多少都是公共常数：

$$g_j = \log(B/n_H),$$

会被最终 softmax抵消，因此任何 B 都是 no-op。

6. B 对梯度并非“只改变大小”

令：

$$d_j = \frac{\partial L}{\partial z_j}.$$

对于 normalized gate：

$$\frac{\partial g_j}{\partial s_k} = \mathbf{1}[j = k] - r_k,$$

所以：

$$\boxed{\frac{\partial L}{\partial s_k} = d_k - r_k \sum_{j \in H} d_j.}$$

这里局部 Jacobian $\partial g / \partial s$ 的确不显式含 B。

但 d_j 来自最终 attention forward，而最终 attention 已经随 B 改变。因此：

- gradient magnitude可能改变；
- gradient direction也可能改变；
- 并不是统一乘上一个标量。

还可以直接写：

$$\boxed{\frac{\partial L}{\partial \log B} = \sum_{j \in H} d_j.}$$

在有 sink 时，这一般不为0，说明 loss本身直接依赖 B。无 sink时，history就是全部可见 keys，而softmax logit梯度行和为0，因此该导数为0。

7. 最小 sink-4 数值反例

取一个 query row：

- 1个 history key；
- 4个 visible sink keys；
- 所有原始 attention logits均为0；
- history score $s = 0$ 。

此时：

$$\text{LSE}(s) = 0.$$

$$B = 1$$

history gate:

$$g_H = 0 - 0 + \log 1 = 0.$$

四个 sink gate也都是0。因此五个logits完全相同:

$$\alpha_H = \alpha_{P_1} = \dots = \alpha_{P_4} = \frac{1}{5}.$$

这是精确 dense no-op。

$$B = 4$$

history gate:

$$g_H = \log 4.$$

于是 multiplier 为:

- history: 4;
- 每个 sink: 1。

最终:

$$\alpha_H = \frac{4}{4 + 4} = \frac{1}{2},$$
$$\alpha_{P_i} = \frac{1}{4 + 4} = \frac{1}{8}.$$

dense baseline原本每个token都是:

$$\frac{1}{5}.$$

所以仅把 B 从1改为4, 就把 history-vs-sink odds 从:

$$1 : 1$$

改为:

$$4 : 1,$$

并且从精确no-op变成明显非no-op。

这已经直接推翻“B不影响no-op或相对关系”。

最终判定: 部分正确, 但对当前 sink-4 的核心结论是错误的

Claude唯一正确的部分是:

- B 不改变 history 内部的相对排序和attention odds;

- 没有sink或其他ungated reference时，B会被softmax完全抵消。

但在当前 full-scope sink-4 中：

- B 明确改变 history-vs-sink 的相对关系；
- B 明确改变 forward attention mass；
- B 明确改变 normalized flat gate 的dense no-op条件；
- B 对router gradient不只是改变大小，也可能改变方向。

因此“B只影响梯度大小，不影响no-op或相对关系”作为对当前配置的整体判断，**是错误的**。

ChatGPT 也可能会犯错。请核查重要信息。